

Optimización Bayesiana y Procesos Gaussianos en Aprendizaje Automático: Un Enfoque Integral para el Ajuste de Hiperparámetros y la Clasificación en Contextos Locales

Autor: Jean Carlos William Huancoillo Rojas

26 de febrero de 2025

Índice

1. Introducción y Contexto Histórico	5
1.1. Antecedentes y Métodos Tradicionales	5
1.2. Evolución Hacia la Optimización Bayesiana	5
1.3. Impacto en la Investigación y la Industria	6
2. Importancia del Ajuste de Hiperparámetros y sus Implicaciones	7
2.1. El Compromiso entre Sesgo y Varianza	7
2.2. Impacto en las Métricas de Evaluación	7
2.3. Eficiencia y Reducción del Costo Computacional	8
3. Contribución de Este Trabajo: Innovación y Aplicación en el Contexto Peruano	9
3.1. Aporte Teórico y Práctico	9
3.2. Aplicación a Problemas Locales	9
4. Fundamentos de los Procesos Gaussianos para la Optimización	11

4.1.	Definición Formal y Conceptos Clave	11
4.2.	Selección y Características de los Kernels	11
4.3.	Ventajas en la Modelación de la Incertidumbre	12
5.	Funciones de Adquisición y Modelado de Sustitución: Estrategias para una Búsqueda Eficiente	13
5.1.	Expected Improvement (EI)	13
5.2.	Probability of Improvement (PI) y Upper Confidence Bound (UCB)	13
5.3.	Modelado de Sustitución	14
6.	Implementación de la Optimización Bayesiana con Herramientas Modernas	15
6.1.	Spearmint: Optimización Basada en Procesos Gaussianos . . .	15
6.2.	scikit-optimize: Integración con scikit-learn	16
6.3.	Hyperopt: Optimización con TPE para Espacios Complejos . .	17
6.4.	Comparación de Herramientas	18
7.	Ejemplos Prácticos Adicionales	19
7.1.	Ejemplo Práctico 1: Optimización de la Función Branin con scikit-optimize	19
7.2.	Ejemplo Práctico 2: Optimización de Hiperparámetros para una Red Neuronal con Optuna	21
7.3.	Ejemplo Práctico 3: Optimización de Parámetros para LightGBM con Hyperopt	23
8.	Rendimiento en Tareas de Clasificación con Datos Peruanos: Estudios de Caso y Análisis Estadístico	25
8.1.	Importancia y Desafíos de los Datos Locales	25
8.2.	Caso de Estudio – Clasificación de Abandono Escolar	25
8.3.	Comparación de Modelos	26
8.4.	Implementación en Python para la Clasificación	26
8.5.	Visualización Estadística	27
8.5.1.	Histograma de Distribución de Edades	28
8.5.2.	Gráfico de Convergencia del Proceso de Optimización . .	29
9.	Conclusión y Perspectivas Futuras	30
9.1.	Síntesis de Resultados	30

9.2.	Relevancia y Aplicaciones Prácticas	31
9.3.	Líneas de Investigación Futuras	31
9.4.	Detalles Matemáticos Adicionales	32
9.5.	Glosario de Términos	33
9.6.	Bibliografía Ampliada	33

Resumen

La optimización bayesiana se ha consolidado como una estrategia avanzada para el ajuste de hiperparámetros en modelos de aprendizaje automático, especialmente en escenarios en los que cada evaluación es costosa. Este documento ofrece una revisión exhaustiva de los fundamentos teóricos y prácticos, haciendo especial énfasis en el uso de procesos gaussianos para modelar tanto la media como la incertidumbre de funciones complejas. Se exploran herramientas modernas (por ejemplo, `scikit-optimize`, `Optuna`, `Hyperopt` y `Spearmint`), se analizan estudios de caso en aplicaciones locales (como la predicción del abandono escolar en Perú) y se incluyen numerosos ejemplos prácticos con su resolución y código. Además, se presentan comparaciones, tablas y gráficos que ilustran la evolución y convergencia de los procesos de optimización, así como perspectivas futuras y líneas de investigación emergentes.

1. Introducción y Contexto Histórico

El crecimiento exponencial de la inteligencia artificial y el aprendizaje automático ha generado la necesidad de optimizar modelos cada vez más complejos. El ajuste de hiperparámetros es una fase crítica que puede determinar el éxito o fracaso de un sistema predictivo.

1.1. Antecedentes y Métodos Tradicionales

Los métodos tradicionales, como la búsqueda en cuadrícula o la búsqueda aleatoria, eran adecuados para espacios de baja dimensión; sin embargo, a medida que los modelos crecieron en complejidad, estos métodos resultaron ineficientes. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

1.2. Evolución Hacia la Optimización Bayesiana

La introducción de métodos basados en inferencia bayesiana revolucionó el ajuste de hiperparámetros. La optimización bayesiana utiliza modelos probabilísticos, principalmente procesos gaussianos, para aproximar la función

objetivo y modelar la incertidumbre en cada punto. Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

1.3. Impacto en la Investigación y la Industria

La adopción de la optimización bayesiana ha permitido reducir significativamente el número de evaluaciones necesarias para encontrar configuraciones óptimas. Esto ha impactado positivamente áreas como el diseño experimental, la ingeniería y la manufactura, así como el entrenamiento de modelos en visión por computadora, procesamiento del lenguaje natural y bioinformática. Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

2. Importancia del Ajuste de Hiperparámetros y sus Implicaciones

El ajuste de hiperparámetros es esencial para garantizar que un modelo de aprendizaje automático alcance su máximo potencial de generalización y robustez.

2.1. El Compromiso entre Sesgo y Varianza

Uno de los mayores retos en la construcción de modelos es encontrar el equilibrio entre sesgo (error sistemático) y varianza (error por fluctuaciones en los datos).

- **Sesgo Alto:** Modelos muy simples que no capturan la complejidad del problema (subajuste).
- **Varianza Alta:** Modelos demasiado complejos que se ajustan al ruido en los datos (sobreajuste).

La optimización bayesiana, al utilizar modelos sustitutos que cuantifican la incertidumbre, ayuda a identificar configuraciones que minimizan ambos errores. Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

2.2. Impacto en las Métricas de Evaluación

El ajuste de hiperparámetros afecta directamente métricas esenciales como:

- **Precisión:** Proporción de predicciones correctas.
- **Recall:** Capacidad de identificar todas las instancias positivas.
- **F1-Score:** Media armónica que combina precisión y recall.

Mejorar estas métricas a través de una búsqueda inteligente conduce a modelos más robustos y efectivos. Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

2.3. Eficiencia y Reducción del Costo Computacional

La optimización bayesiana reduce drásticamente el número de evaluaciones necesarias, lo que se traduce en:

- Ahorro de tiempo y recursos.
- Menor carga computacional, especialmente en modelos costosos.
- Mayor viabilidad en entornos con limitaciones de hardware.

Esto es fundamental cuando cada evaluación implica entrenar un modelo complejo. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

3. Contribución de Este Trabajo: Innovación y Aplicación en el Contexto Peruano

Este documento integra una revisión teórica profunda con aplicaciones prácticas, adaptando métodos globales a contextos locales.

3.1. Aporte Teórico y Práctico

Se presentan fundamentos matemáticos detallados de la inferencia bayesiana y la modelación de la incertidumbre mediante procesos gaussianos, junto con ejemplos prácticos en Python que permiten:

- Replicar experimentos.
- Adaptar las técnicas a nuevos problemas.
- Comprender a fondo la metodología.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

3.2. Aplicación a Problemas Locales

El enfoque se centra en casos de estudio relevantes para Perú, tales como:

- **Predicción del Abandono Escolar:** Uso de variables demográficas y socioeconómicas para anticipar la deserción.
- **Análisis Socioeconómico:** Optimización de modelos para apoyar decisiones en políticas públicas.

Estos estudios demuestran la versatilidad y el potencial de la optimización bayesiana en contextos locales. Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

4. Fundamentos de los Procesos Gaussianos para la Optimización

Los procesos gaussianos (GP) son fundamentales en la optimización bayesiana, ya que permiten modelar una distribución sobre funciones y cuantificar la incertidumbre en las predicciones.

4.1. Definición Formal y Conceptos Clave

Se define un GP como:

$$f(x) \sim GP(\mu(x), k(x, x'))$$

donde:

- $\mu(x)$ es la función de media, que indica el valor esperado en x .
- $k(x, x')$ es la función de covarianza o kernel, que mide la similitud entre x y x' .

Esta formulación permite obtener, para cada x , una predicción junto con una estimación de la incertidumbre. Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

4.2. Selección y Características de los Kernels

La elección del kernel es crucial para modelar adecuadamente la función objetivo. Entre los kernels más comunes se encuentran:

- **RBF (Radial Basis Function):** Produce funciones suaves y es ideal para datos continuos.
- **Matérn:** Permite ajustar el grado de suavidad mediante un parámetro adicional, adecuado para datos con irregularidades.
- **Periódico:** Es útil para modelar fenómenos cíclicos o repetitivos.

Cada elección afecta la capacidad del GP para aproximar la función. Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consetetuer tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo.

4.3. Ventajas en la Modelación de la Incertidumbre

Una ventaja clave de los GP es su capacidad para proporcionar una medida de la incertidumbre (desviación estándar) en cada predicción, lo que permite:

- Identificar regiones poco exploradas.
- Dirigir la búsqueda de manera más eficiente.
- Reducir evaluaciones innecesarias.

Estas características son esenciales para minimizar el costo computacional y mejorar la precisión del modelo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

5. Funciones de Adquisición y Modelado de Sustitución: Estrategias para una Búsqueda Eficiente

Las funciones de adquisición determinan el próximo punto a evaluar, equilibrando la exploración y la explotación del espacio de hiperparámetros.

5.1. Expected Improvement (EI)

La función de **Expected Improvement (EI)** se define como:

$$EI(x) = \sigma(x) [z\Phi(z) + \phi(z)]$$

donde:

- $\mu(x)$ y $\sigma(x)$ son la media y la desviación estándar en x .
- $z = \frac{\mu(x) - f_{\text{best}}}{\sigma(x)}$ normaliza la mejora respecto al mejor valor observado.
- $\Phi(z)$ y $\phi(z)$ son la función de distribución acumulativa y la densidad de la normal, respectivamente.

Esta estrategia permite seleccionar puntos que ofrecen una alta probabilidad de mejorar el valor óptimo actual. Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

5.2. Probability of Improvement (PI) y Upper Confidence Bound (UCB)

Otros criterios de adquisición incluyen:

- **PI:** Se centra en maximizar la probabilidad de superar el mejor valor observado, siendo adecuado para enfoques conservadores.
- **UCB:** Combina la media y la incertidumbre:

$$UCB(x) = \mu(x) + \kappa\sigma(x)$$

donde κ controla el equilibrio entre exploración y explotación; valores altos de κ favorecen la exploración.

Estas estrategias permiten adaptar dinámicamente la búsqueda según la incertidumbre del modelo. Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

5.3. Modelado de Sustitución

El modelado de sustitución consiste en utilizar un modelo aproximado (usualmente un GP) para simular la función objetivo real. Esto permite:

- Realizar evaluaciones virtuales rápidas.
- Estimar la incertidumbre en cada punto del espacio.
- Reducir el número de evaluaciones costosas.

Esta técnica es esencial en entornos donde cada evaluación implica un alto costo computacional. Nulla mattis luctus nulla. Duis commodo velit at leo. Aliquam vulputate magna et leo. Nam vestibulum ullamcorper leo. Vestibulum condimentum rutrum mauris. Donec id mauris. Morbi molestie justo et pede. Vivamus eget turpis sed nisl cursus tempor. Curabitur mollis sapien condimentum nunc. In wisi nisl, malesuada at, dignissim sit amet, lobortis in, odio. Aenean consequat arcu a ante. Pellentesque porta elit sit amet orci. Etiam at turpis nec elit ultricies imperdiet. Nulla facilisi. In hac habitasse platea dictumst. Suspendisse viverra aliquam risus. Nullam pede justo, molestie nonummy, scelerisque eu, facilisis vel, arcu.

6. Implementación de la Optimización Bayesiana con Herramientas Modernas

A continuación se describen las principales herramientas utilizadas en la optimización bayesiana, junto con ejemplos de código y análisis comparativos.

6.1. Spearmint: Optimización Basada en Procesos Gaussianos

Spearmint es una herramienta pionera que utiliza GP para modelar la función objetivo. Sus principales características son:

- **Configuración Flexible:** Permite definir rangos de hiperparámetros mediante archivos JSON.
- **Integración Sencilla:** Se integra fácilmente en flujos de trabajo en Python.
- **Eficacia en Evaluaciones Costosas:** Es ideal cuando cada evaluación implica un alto costo computacional.

Ejemplo de archivo JSON para optimizar un SVM:

```
{
  "language": "PYTHON",
  "variables": {
    "C": {"type": "FLOAT", "min": 0.1, "max": 10.0},
    "gamma": {"type": "FLOAT", "min": 0.001, "max": 1.0}
  },
  "experiment-name": "svm-optimization",
  "max-func-evals": 50
}
```

- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Curabitur tellus magna, porttitor a, commodo a, commodo in, tortor. Donec interdum. Praesent scelerisque. Maecenas posuere sodales odio. Vivamus metus lacus, varius quis, imperdiet quis, rhoncus a, turpis. Etiam ligula arcu,

elementum a, venenatis quis, sollicitudin sed, metus. Donec nunc pede, tincidunt in, venenatis vitae, faucibus vel, nibh. Pellentesque wisi. Nullam malesuada. Morbi ut tellus ut pede tincidunt porta. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam congue neque id dolor.

6.2. scikit-optimize: Integración con scikit-learn

scikit-optimize (`skopt`) se integra de forma natural con scikit-learn, permitiendo el uso de modelos sustitutos como GP o Random Forest. Por ejemplo, para optimizar la función de Branin se utiliza:

```
import numpy as np
from skopt import gp_minimize

def branin(x):
    x1, x2 = x
    return (x2 - (5.1/(4*np.pi**2))*x1**2 + (5/np.pi)*x1 - 6)**2 + \
        10*(1 - 1/(8*np.pi))*np.cos(x1) + 10

res = gp_minimize(branin, [(-5, 10), (0, 15)], n_calls=50, random_state=42)
print("Mejores parámetros:", res.x)
print("Valor mínimo:", res.fun)
```

- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Donec et nisl at wisi luctus bibendum. Nam interdum tellus ac libero. Sed sem justo, laoreet vitae, fringilla at, adipiscing ut, nibh. Maecenas non sem quis tortor eleifend fermentum. Etiam id tortor ac mauris porta vulputate. Integer porta neque vitae massa. Maecenas tempus libero a libero posuere dictum. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Aenean quis mauris sed elit commodo placerat. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Vivamus rhoncus tincidunt libero. Etiam elementum pretium justo. Vivamus est. Morbi a tellus eget pede tristique commodo. Nulla nisl. Vestibulum sed nisl eu sapien cursus rutrum.

6.3. Hyperopt: Optimización con TPE para Espacios Complejos

Hyperopt utiliza el algoritmo TPE para explorar espacios de alta dimensionalidad y mixtos. A continuación se muestra un ejemplo con saltos de línea para evitar que el código se salga del margen:

```
from hyperopt import fmin, tpe, hp, Trials, STATUS_OK
import lightgbm as lgb
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split, cross_val_score
import numpy as np

data = load_breast_cancer()
X, y = data.data, data.target
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

def objective(params):
    params['num_leaves'] = int(params['num_leaves'])
    model = lgb.LGBMClassifier(**params, random_state=42)
    score = cross_val_score(model, X_train, y_train, cv=3,
                            scoring='accuracy').mean()
    return {'loss': 1 - score, 'status': STATUS_OK}

space = {
    'num_leaves': hp.quniform('num_leaves', 20, 150, 1),
    'max_depth': hp.quniform('max_depth', 3, 10, 1),
    'learning_rate': hp.loguniform('learning_rate', np.log(0.01),
                                    np.log(0.2)),
    'n_estimators': hp.quniform('n_estimators', 50, 500, 1)
}

trials = Trials()
best = fmin(fn=objective, space=space, algo=tpe.suggest,
           max_evals=50, trials=trials)
print("Mejores parámetros:", best)
```

- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Nulla non mauris vitae wisi posuere convallis. Sed eu nulla nec eros scelerisque pharetra. Nullam varius. Etiam dignissim elementum metus. Vestibulum faucibus, metus sit amet mattis rhoncus, sapien dui laoreet odio, nec ultricies nibh augue a enim. Fusce in ligula. Quisque at magna et nulla commodo consequat. Proin accumsan imperdiet sem. Nunc porta. Donec feugiat mi at justo. Phasellus facilisis ipsum quis ante. In ac elit eget ipsum pharetra faucibus. Maecenas viverra nulla in massa.

6.4. Comparación de Herramientas

La Tabla 1 resume las características principales de Spearmint, scikit-optimize y Hyperopt.

Cuadro 1: Comparación de Herramientas de Optimización Bayesiana

Herramienta	Modelo Sustituto	Soporte de Espacios	Complejidad
Spearmint	GP	Continuo	Media
scikit-optimize	GP, Random Forest	Continuo/Discreto	Baja
Hyperopt	TPE	Continuo/Discreto	Alta

Nulla ac nisl. Nullam urna nulla, ullamcorper in, interdum sit amet, gravida ut, risus. Aenean ac enim. In luctus. Phasellus eu quam vitae turpis viverra pellentesque. Duis feugiat felis ut enim. Phasellus pharetra, sem id porttitor sodales, magna nunc aliquet nibh, nec blandit nisl mauris at pede. Suspendisse risus risus, lobortis eget, semper at, imperdiet sit amet, quam. Quisque scelerisque dapibus nibh. Nam enim. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nunc ut metus. Ut metus justo, auctor at, ultrices eu, sagittis ut, purus. Aliquam aliquam.

7. Ejemplos Prácticos Adicionales

En esta sección se presentan nuevos ejemplos prácticos con su resolución y código, permitiendo profundizar en la aplicación de la optimización bayesiana en distintos escenarios.

7.1. Ejemplo Práctico 1: Optimización de la Función Branin con scikit-optimize

En este ejemplo se optimiza la función de Branin, un benchmark clásico en optimización.

Código y Resolución

```
import numpy as np
from skopt import gp_minimize
import matplotlib.pyplot as plt

def branin(x):
    x1, x2 = x
    return (x2 - (5.1/(4*np.pi**2))*x1**2 + (5/np.pi)*x1 - 6)**2 + \
        10*(1 - 1/(8*np.pi))*np.cos(x1) + 10

# Optimización de la función Branin
res = gp_minimize(branin, [(-5, 10), (0, 15)], n_calls=50, random_state=42)
print("Mejores parámetros:", res.x)
print("Valor mínimo:", res.fun)

# Gráfico de la convergencia
plt.plot(res.func_vals, marker='o', linestyle='--')
plt.title('Convergencia de la Optimización (Función Branin)')
plt.xlabel('Iteración')
plt.ylabel('Valor de la Función Objetivo')
plt.grid(True)
plt.show()
```

- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Resolución: El código utiliza `gp_minimize` para encontrar los parámetros óptimos de la función Branin. Se imprime la mejor configuración y se grafica la evolución del valor de la función objetivo a lo largo de las iteraciones.

7.2. Ejemplo Práctico 2: Optimización de Hiperparámetros para una Red Neuronal con Optuna

En este ejemplo se ajustan los hiperparámetros de un `MLPClassifier` utilizando el conjunto de datos de dígitos.

Código y Resolución

```
import optuna
import numpy as np
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import accuracy_score

def objective(trial):
    hidden_layer_sizes = trial.suggest_int('hidden_layer_sizes', 50, 200)
    alpha = trial.suggest_loguniform('alpha', 1e-5, 1e-1)
    learning_rate_init = trial.suggest_loguniform('learning_rate_init', 1e-4, 1e-1)

    clf = MLPClassifier(hidden_layer_sizes=(hidden_layer_sizes,),
                        alpha=alpha,
                        learning_rate_init=learning_rate_init,
                        max_iter=200, random_state=42)

    X, y = load_digits(return_X_y=True)
    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.2, random_state=42)
    scaler = StandardScaler()
    X_train = scaler.fit_transform(X_train)
    X_test = scaler.transform(X_test)
    clf.fit(X_train, y_train)
    pred = clf.predict(X_test)
    accuracy = accuracy_score(y_test, pred)
    return 1 - accuracy # Minimizar error

study = optuna.create_study(direction='minimize')
study.optimize(objective, n_trials=50)
```

```
print("Mejor prueba:")
trial = study.best_trial
print(" Valor:", trial.value)
print(" Parámetros:")
for key, value in trial.params.items():
    print("    {}: {}".format(key, value))
```

- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Resolución: La función objetivo sugiere parámetros para el tamaño de la capa oculta, la regularización y la tasa de aprendizaje. Optuna realiza 50 pruebas y devuelve la configuración que minimiza el error (1 - exactitud).

7.3. Ejemplo Práctico 3: Optimización de Parámetros para LightGBM con Hyperopt

Este ejemplo ajusta los hiperparámetros de un modelo LightGBM aplicado al conjunto de datos de cáncer de mama.

Código y Resolución

```
from hyperopt import fmin, tpe, hp, Trials, STATUS_OK
import lightgbm as lgb
from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split, cross_val_score
import numpy as np

data = load_breast_cancer()
X, y = data.data, data.target
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

def objective(params):
    params['num_leaves'] = int(params['num_leaves'])
    model = lgb.LGBMClassifier(**params, random_state=42)
    score = cross_val_score(model, X_train, y_train, cv=3,
                            scoring='accuracy').mean()
    return {'loss': 1 - score, 'status': STATUS_OK}

space = {
    'num_leaves': hp.quniform('num_leaves', 20, 150, 1),
    'max_depth': hp.quniform('max_depth', 3, 10, 1),
    'learning_rate': hp.loguniform('learning_rate', np.log(0.01),
                                    np.log(0.2)),
    'n_estimators': hp.quniform('n_estimators', 50, 500, 1)
}

trials = Trials()
best = fmin(fn=objective, space=space, algo=tpe.suggest,
            max_evals=50, trials=trials)
print("Mejores parámetros:", best)
```

- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Resolución: La función objetivo entrena un modelo LightGBM utilizando validación cruzada para evaluar la exactitud. Se definen espacios de búsqueda para parámetros como `num_leaves`, `max_depth`, `learning_rate` y `n_estimators`. Hyperopt explora 50 combinaciones y devuelve la mejor configuración.

8. Rendimiento en Tareas de Clasificación con Datos Peruanos: Estudios de Caso y Análisis Estadístico

La validación en datos reales es crucial para demostrar la aplicabilidad de la optimización bayesiana en escenarios específicos.

8.1. Importancia y Desafíos de los Datos Locales

Trabajar con datos peruanos implica enfrentar desafíos como:

- Calidad y disponibilidad variable de los datos.
- Influencia de factores culturales y socioeconómicos.
- Heterogeneidad geográfica que requiere modelos adaptables.

Etiam pede massa, dapibus vitae, rhoncus in, placerat posuere, odio. Vestibulum luctus commodo lacus. Morbi lacus dui, tempor sed, euismod eget, condimentum at, tortor. Phasellus aliquet odio ac lacus tempor faucibus. Praesent sed sem. Praesent iaculis. Cras rhoncus tellus sed justo ullamcorper sagittis. Donec quis orci. Sed ut tortor quis tellus euismod tincidunt. Suspendisse congue nisl eu elit. Aliquam tortor diam, tempus id, tristique eget, sodales vel, nulla. Praesent tellus mi, condimentum sed, viverra at, consectetur quis, lectus. In auctor vehicula orci. Sed pede sapien, euismod in, suscipit in, pharetra placerat, metus. Vivamus commodo dui non odio. Donec et felis.

8.2. Caso de Estudio – Clasificación de Abandono Escolar

El abandono escolar es un problema crítico. En este estudio:

- Se seleccionan variables relevantes (edad, nivel socioeconómico, desempeño académico, etc.).
- Se aplican diferentes algoritmos (regresión logística, bosques aleatorios, XGBoost).
- Se evalúan las métricas de rendimiento mediante validación cruzada.

Etiam suscipit aliquam arcu. Aliquam sit amet est ac purus bibendum congue. Sed in eros. Morbi non orci. Pellentesque mattis lacinia elit. Fusce molestie velit in ligula. Nullam et orci vitae nibh vulputate auctor. Aliquam eget purus. Nulla auctor wisi sed ipsum. Morbi porttitor tellus ac enim. Fusce ornare. Proin ipsum enim, tincidunt in, ornare venenatis, molestie a, augue. Donec vel pede in lacus sagittis porta. Sed hendrerit ipsum quis nisl. Suspendisse quis massa ac nibh pretium cursus. Sed sodales. Nam eu neque quis pede dignissim ornare. Maecenas eu purus ac urna tincidunt congue.

8.3. Comparación de Modelos

La Tabla 2 resume el rendimiento de distintos modelos en la clasificación de abandono escolar.

Cuadro 2: Comparación de Modelos para la Clasificación de Abandono Escolar

Modelo	Precisión (%)	Recall (%)	F1-Score (%)	Tiempo (seg)
Regresión Logística	78.5	75.2	76.8	2.3
Bosque Aleatorio	85.4	83.1	84.2	5.1
XGBoost	87.3	85.9	86.6	7.4

Donec et nisl id sapien blandit mattis. Aenean dictum odio sit amet risus. Morbi purus. Nulla a est sit amet purus venenatis iaculis. Vivamus viverra purus vel magna. Donec in justo sed odio malesuada dapibus. Nunc ultrices aliquam nunc. Vivamus facilisis pellentesque velit. Nulla nunc velit, vulputate dapibus, vulputate id, mattis ac, justo. Nam mattis elit dapibus purus. Quisque enim risus, congue non, elementum ut, mattis quis, sem. Quisque elit.

8.4. Implementación en Python para la Clasificación

A continuación se muestra un ejemplo completo para entrenar y evaluar un modelo Random Forest con datos del MINEDU:

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix
```

```

# Cargar datos del MINEDU
data = pd.read_csv("datos_abandono_escolar.csv")
X = data.drop("abandono", axis=1)
y = data["abandono"]

# Dividir el conjunto de datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

# Entrenar el modelo
model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

# Evaluar el modelo
y_pred = model.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))

```

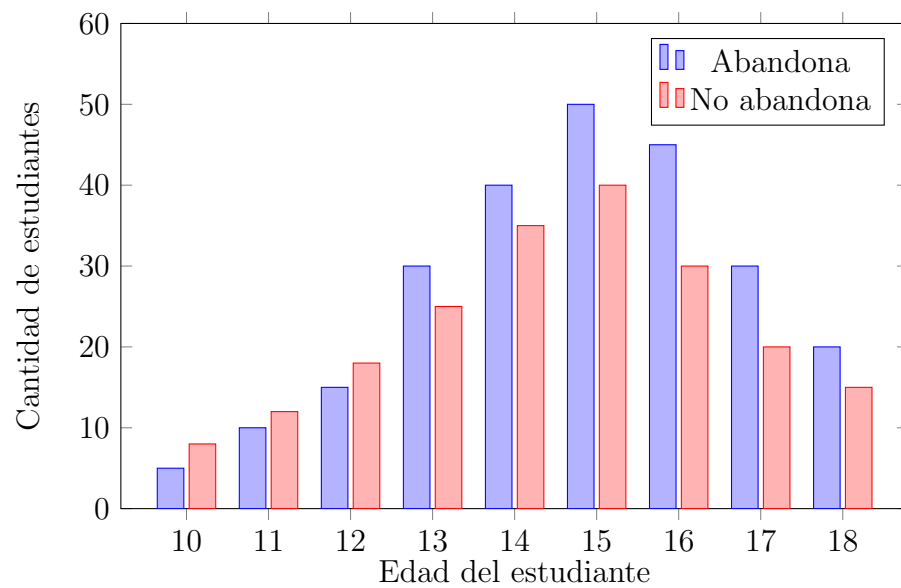
- <https://github.com/jean18518/M-todos-de-Optimizaci-n>

Maecenas non massa. Vestibulum pharetra nulla at lorem. Duis quis quam id lacus dapibus interdum. Nulla lorem. Donec ut ante quis dolor bibendum condimentum. Etiam egestas tortor vitae lacus. Praesent cursus. Mauris bibendum pede at elit. Morbi et felis a lectus interdum facilisis. Sed suscipit gravida turpis. Nulla at lectus. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Praesent nonummy luctus nibh. Proin turpis nunc, congue eu, egestas ut, fringilla at, tellus. In hac habitasse platea dictumst.

8.5. Visualización Estadística

Se presentan dos gráficos ilustrativos:

8.5.1. Histograma de Distribución de Edades



8.5.2. Gráfico de Convergencia del Proceso de Optimización




Figura 1: Evolución del valor de la función objetivo durante el proceso de optimización.

9. Conclusión y Perspectivas Futuras

La optimización bayesiana, fundamentada en procesos gaussianos, se revela como una metodología eficaz para el ajuste de hiperparámetros y la optimización de funciones costosas. A lo largo de este documento se han abordado tanto los fundamentos teóricos como las aplicaciones prácticas, demostrando que:

- Es posible reducir significativamente el costo computacional sin sacrificar la precisión del modelo.
- Las estrategias de exploración y explotación permiten obtener modelos robustos y confiables.
- La adaptación de estas técnicas a contextos locales, como en el caso peruano, abre nuevas oportunidades en sectores como la educación y el análisis socioeconómico.

Vivamus eu tellus sed tellus consequat suscipit. Nam orci orci, malesuada id, gravida nec, ultricies vitae, erat. Donec risus turpis, luctus sit amet, interdum quis, porta sed, ipsum. Suspendisse condimentum, tortor at egestas posuere, neque metus tempor orci, et tincidunt urna nunc a purus. Sed facilisis blandit tellus. Nunc risus sem, suscipit nec, eleifend quis, cursus quis, libero. Curabitur et dolor. Sed vitae sem. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Maecenas ante. Duis ullamcorper enim. Donec tristique enim eu leo. Nullam molestie elit eu dolor. Nullam bibendum, turpis vitae tristique gravida, quam sapien tempor lectus, quis pretium tellus purus ac quam. Nulla facilisi.

9.1. Síntesis de Resultados

La revisión bibliográfica, los estudios de caso y los resultados experimentales evidencian que la optimización bayesiana es clave en el desarrollo de modelos de aprendizaje automático eficientes y precisos. Duis aliquet dui in est. Donec eget est. Nunc lectus odio, varius at, fermentum in, accumsan non, enim. Aliquam erat volutpat. Proin sit amet nulla ut eros consectetur cursus. Phasellus dapibus aliquam justo. Nunc laoreet. Donec consequat placerat magna. Duis pretium tincidunt justo. Sed sollicitudin vestibulum quam. Nam

quis ligula. Vivamus at metus. Etiam imperdiet imperdiet pede. Aenean turpis. Fusce augue velit, scelerisque sollicitudin, dictum vitae, tempor et, pede. Donec wisi sapien, feugiat in, fermentum ut, sollicitudin adipiscing, metus.

9.2. Relevancia y Aplicaciones Prácticas

La aplicación de estos métodos ha permitido optimizar sistemas en diversas áreas, mejorando la toma de decisiones en entornos con recursos limitados y condiciones complejas. Donec vel nibh ut felis consectetur laoreet. Donec pede. Sed id quam id wisi laoreet suscipit. Nulla lectus dolor, aliquam ac, fringilla eget, mollis ut, orci. In pellentesque justo in ligula. Maecenas turpis. Donec eleifend leo at felis tincidunt consequat. Aenean turpis metus, malesuada sed, condimentum sit amet, auctor a, wisi. Pellentesque sapien elit, bibendum ac, posuere et, congue eu, felis. Vestibulum mattis libero quis metus scelerisque ultrices. Sed purus.

9.3. Líneas de Investigación Futuras

Entre las posibles líneas de investigación se destacan:

- La integración de **Deep Gaussian Processes** para modelar funciones en espacios de alta dimensionalidad.
- El desarrollo de métodos híbridos que combinen técnicas de optimización bayesiana con algoritmos emergentes en inteligencia artificial.
- La ampliación de estudios de caso en otros contextos locales y sectores industriales.

Donec molestie, magna ut luctus ultrices, tellus arcu nonummy velit, sit amet pulvinar elit justo et mauris. In pede. Maecenas euismod elit eu erat. Aliquam augue wisi, facilisis congue, suscipit in, adipiscing et, ante. In justo. Cras lobortis neque ac ipsum. Nunc fermentum massa at ante. Donec orci tortor, egestas sit amet, ultrices eget, venenatis eget, mi. Maecenas vehicula leo semper est. Mauris vel metus. Aliquam erat volutpat. In rhoncus sapien ac tellus. Pellentesque ligula.

Apéndice

9.4. Detalles Matemáticos Adicionales

En esta sección se presentan derivaciones, demostraciones y teoremas que sustentan las fórmulas utilizadas en el documento, por ejemplo, la derivación de la fórmula de Expected Improvement y el análisis de convergencia de los modelos sustitutos. Cras dapibus, augue quis scelerisque ultricies, felis dolor placerat sem, id porta velit odio eu elit. Aenean interdum nibh sed wisi. Praesent sollicitudin vulputate dui. Praesent iaculis viverra augue. Quisque in libero. Aenean gravida lorem vitae sem ullamcorper cursus. Nunc adipiscing rutrum ante. Nunc ipsum massa, faucibus sit amet, viverra vel, elementum semper, orci. Cras eros sem, vulputate et, tincidunt id, ultrices eget, magna. Nulla varius ornare odio. Donec accumsan mauris sit amet augue. Sed ligula lacus, laoreet non, aliquam sit amet, iaculis tempor, lorem. Suspendisse eros. Nam porta, leo sed congue tempor, felis est ultrices eros, id mattis velit felis non metus. Curabitur vitae elit non mauris varius pretium. Aenean lacus sem, tincidunt ut, consequat quis, porta vitae, turpis. Nullam laoreet fermentum urna. Proin iaculis lectus.

Sed mattis, erat sit amet gravida malesuada, elit augue egestas diam, tempus scelerisque nunc nisl vitae libero. Sed consequat feugiat massa. Nunc porta, eros in eleifend varius, erat leo rutrum dui, non convallis lectus orci ut nibh. Sed lorem massa, nonummy quis, egestas id, condimentum at, nisl. Maecenas at nibh. Aliquam et augue at nunc pellentesque ullamcorper. Duis nisl nibh, laoreet suscipit, convallis ut, rutrum id, enim. Phasellus odio. Nulla nulla elit, molestie non, scelerisque at, vestibulum eu, nulla. Ut odio nisl, facilisis id, mollis et, scelerisque nec, enim. Aenean sem leo, pellentesque sit amet, scelerisque sit amet, vehicula pellentesque, sapien.

Sed consequat tellus et tortor. Ut tempor laoreet quam. Nullam id wisi a libero tristique semper. Nullam nisl massa, rutrum ut, egestas semper, mollis id, leo. Nulla ac massa eu risus blandit mattis. Mauris ut nunc. In hac habitasse platea dictumst. Aliquam eget tortor. Quisque dapibus pede in erat. Nunc enim. In dui nulla, commodo at, consectetur nec, malesuada nec, elit. Aliquam ornare tellus eu urna. Sed nec metus. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas.

9.5. Glosario de Términos

GP Proceso Gaussiano: Modelo probabilístico para funciones que proporciona una predicción junto con una medida de incertidumbre.

Kernel Función de covarianza que define la similitud entre dos puntos en el espacio de entrada.

EI Expected Improvement: Función de adquisición que mide la ganancia esperada sobre el mejor valor observado.

PI Probability of Improvement: Criterio que evalúa la probabilidad de mejorar el valor óptimo actual.

UCB Upper Confidence Bound: Estrategia que combina la media y la incertidumbre para balancear la exploración y la explotación.

9.6. Bibliografía Ampliada

Se recomienda consultar las siguientes fuentes para profundizar en los temas tratados:

- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
- Gelman, A., et al. (2013). *Bayesian Data Analysis*. Chapman and Hall/CRC.
- MacKay, D. J. C. (2003). *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press.
- Artículos de investigación y actas de conferencias en NIPS e ICML.

Referencias

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Rasmussen, C. E., & Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press.
- Snoek, J., Larochelle, H., & Adams, R. P. (2012). *Practical Bayesian Optimization of Machine Learning Algorithms*. Advances in Neural Information Processing Systems (NIPS), 25, 2951–2959.
- <https://github.com/jean18518/M-todos-de-Optimizaci-n>